

即将发表的文章

基于结构感知的多任务学习与领域泛化技术在稳健椎体分析中的应用

脊柱CT

接收日期: 2025年10月16日

接受日期: 2025年12月16日

杜建阳、葛恒安、张瑞、陈正汉、张玉欣、白宇琪、徐宏浩、丁峰、张永超、叶娟、严一航、黄少山、黄景彪

引用本文为: 杜, J., 葛, H. Zhang, R.等.结构感知多任务学习
脊柱CT中强健椎体分析的泛化应用。
npjDigit.Med.
(2026).<https://doi.org/10.1038/s41746-025-02288-5>

我们提供本手稿的未编辑版本, 以便早期获取其研究结果。在最终发表前, 本手稿将进行进一步编辑。请注意可能存在影响内容的错误, 且所有法律免责声明均适用。

若本论文采用透明同行评审模式发表, 则同行评审报告将随最终文章一并发布。

作者(们) 2026。开放获取 本文采用知识共享协议4.0国际版授权
本许可协议允许在任何媒介或格式中进行非商业用途的使用、共享、分发及复制, 但需满足以下条件: 1. 对原始作者及来源给予适当署名; 2. 提供知识共享许可协议链接; 3. 明确标注是否对授权材料进行过修改。根据本许可协议, 您无权分享本文衍生的改编材料或其部分内容。本文文件中包含的图像或其他第三方材料
文章内容均采用知识共享许可协议, 除非在引用材料时另有说明。若材料未包含在文章的知识共享许可协议中, 且您的使用目的不符合法定规定或超出许可范围, 则需直接向版权方申请授权。如需查看该许可协议副本, 请 [visithttp://creativecommons.org/licenses/by-nc-nd/4.0](http://creativecommons.org/licenses/by-nc-nd/4.0).

结构感知多任务学习 鲁棒顶点的域泛化 脊柱CT分析

建阳杜^{1,2,3,4}, 河岸葛⁺, 瑞 Zhang^{5,t}, 正汉 Chen⁶,
于欣 Zhang⁷, 8, 于琪 Bai⁹, 洪浩 Xu¹⁰, 冯 Ding²,
Yongchao Zhang², Juan Ye¹¹, Yihang Yang^{2*}, Shaoshan Hu^{1*},
京宝 Huang⁴

¹Cancer 中心, 神经外科, 浙江省
人民医院, 附属人民医院, 杭州医学院
中国浙江省杭州市310006。

² 山东省立医院神经外科, 山东第一医科大学附属医院, 山东省济
南市, 250022, 中国。

浙江大学光学院、工程学院、杭州
310058, 中国浙江。

同济大学医学院附属医院运动医学⁴ Department
中国上海同济大学, 200333。

⁵福州大学附属省立医院骨科
中国福建省福州市325000。

⁶北京大学软件与微电子学院, 北京,
100871, 中国。

上海市第九人民医院口腔外科
上海交通大学医学院附属医院, 上海, 200011,
中国

⁸ 上海骨科植入物重点实验室, 上海第九人民医院
上海交通大学医学院附属人民医院
中国上海, 200011。

⁹ 环境、教育与发展学院
曼彻斯特, 曼彻斯特, M139 PL, 英国。

¹⁰中国上海市同济大学医学院

¹¹Department: 苏州九龙医院放射科
中国江苏省苏州市交通大学医学院附属医院, 215028

通讯作者: yangyihangyy@163.com;

shaoshanhu421@163.com ;jingbiaohuang1@163.com;

通讯作者: jianyangdu@126.com; 2405834@tongji.教育.cn;

zhangrui0591@fzu.教育.cn; zhenghan.陈校友.pku.教育.cn;

雨心张0129@163.com; bai_peking@163.com; xu honghao@163.com;

slyydf6352@163.com ; andy2821@sina.com;

yejuan@kowloonhospital.com;

这些作者对本研究的贡献均等。

摘要

脊柱影像分析在肌肉骨骼系统和神经系统疾病的诊断与治疗中具有关键作用。然而，现有椎体分割方法普遍存在跨临床领域的泛化能力不足，且鲜少涉及椎体识别、病灶定位等下游任务。本研究提出VertebraFormer——一个专为稳健且可泛化脊柱CT分析设计的统一多任务框架。为支持该框架，我们构建了MultiSpine异构基准集，包含来自四个公共与私有数据集的CT容积数据，并标注了椎体分割掩膜、解剖学标签及病理区域。本方法整合了Transformer编码器与任务特定解码器，并采用动态调制单元将特征表示适配至不同影像学领域。

我们通过三个关键任务——椎体分割、椎体编号和病灶定位，在域内和跨域设置下对VertebraFormer进行评估。大量实验表明，VertebraFormer在准确性和鲁棒性方面均优于竞争性基线方法。我们进一步通过消融实验、扰动实验和效率分析来验证该框架。

关键词：脊柱CT分析、椎体分段、椎体识别
损伤定位、多任务学习、领域泛化、Transformer
网络，医学图像计算

1 引言

脊柱是一种复杂的解剖结构，对承重、活动及神经保护至关重要。脊柱疾病（包括骨折、退行性疾病及神经可塑性损伤）具有高发病率，可导致严重疼痛、功能障碍甚至瘫痪[1,2]。

计算机断层扫描（CT）凭借其高空间分辨率和精细骨性细节的捕捉能力，在脊柱评估中发挥着关键作用。然而，脊柱CT扫描的手动分析过程劳动强度大、耗时长，且易受观察者间差异的影响，这促使了自动化分析系统的开发。

[3,4].

近年来，深度学习已成为椎体分割、定位及识别的主要方法。全卷积网络（FCNs）

[3]、级联架构[5]以及诸如Dense-U-Net[6]和nnU-Net[7]等编码器-解码器设计在椎体分割领域已取得显著性能提升。大型标注数据集（如VerSe[4]和CTSpineK[8]）通过支持鲁棒的监督学习训练，进一步推动了相关研究。除结构分析外，近期研究还整合了病灶检测模块，用于骨折、转移瘤等病理学分析。以及退行性改变[9,10]。

尽管取得了这些进展，仍存在三大主要挑战。首先，结构脊柱在解剖区域（颈椎、胸椎、腰椎）的异质性导致椎体形态与外观存在显著变异[11]。其次，

病变多样性——从细微的皮质变薄到大面积肿瘤浸润——使得正常解剖结构与病理学的联合建模变得复杂。

第三，跨域泛化仍具挑战：当模型应用于来自未见过的机构、扫描仪或协议的CT扫描时，性能常会下降[12-14]。解决这些问题需要能够同时捕捉解剖学规律性和病理变异性的模型，同时保持对域偏移的鲁棒性。

为应对这些挑战，我们提出VertebraFormer——一个统一的多任务框架，用于在异质性CT域中实现可泛化的椎体分割、识别及病变检测。我们的方法整合了：(1)结构感知编码器，可跨脊柱区域建模解剖学上下文；(2)多任务学习范式，联合优化结构与病理学目标[15,16]；(3)领域泛化策略，结合领域条件动态调制与特征对齐[13,17]。在多个公共数据集和跨域评估场景中的大量实验表明，与强基线模型相比，VertebraFormer在域内准确性和域外鲁棒性方面均表现出色。

综上所述，我们的主要贡献包括：结构感知的统一Transformer框架。单个Transformer主干网络在共享特征空间中联合执行椎体分割、解剖结构识别和病灶检测，通过跨任务一致性与全局解剖建模提升准确性，同时避免了对任务特定网络的需求。MultiSpine基准测试采用零样本协议。我们提出MultiSpine多域脊柱CT数据集及留一域评估协议，实现跨域泛化与迁移能力的系统性评估。动态域泛化调制机制。对比域嵌入驱动的动态调制机制在推理阶段执行前馈域条件化，无需访问目标域标签或在线参数更新即可增强对不同模态和机构的鲁棒性。面向临床可用的一体化系统。VertebraFormer在单一模型中实现具有竞争力的准确率、接近实时的推理及可解释的病灶热图，相较于多网络管道降低部署复杂度，但仍需在常规临床应用前进行前瞻性验证。尼科尔用途。

脊柱CT图像的自动分析涵盖多个相互关联的研究方向，包括椎体分割、解剖结构识别、病灶检测、多任务学习以及领域泛化。尽管这些主题各自独立

这些研究虽已独立开展，但最新进展凸显了将它们整合到统一框架中以构建稳健且临床可行系统的重要性。在以下小节中，我们将综述各领域的代表性研究，重点阐述其技术贡献与局限性。

椎体分割与解剖学标记：椎体分割与解剖学标记是自动化脊柱分析的基础。早期研究主要聚焦于开发稳健的分割流程。例如，Lessmann等人[3]提出了一种迭代式全卷积网络，用于同步分割与标记，以确保解剖学一致性。Seku boyina等人[11]通过引入多标签腰椎标注的局部化分割策略，进一步发展了这一理念。CTSpinelK[8]和VerSe[4]等大规模数据集的发布，推动了高容量架构的发展，包括Dense-U-Net[6]、级联CNNs[5]，nnU-Net[7]，attention-enhanced U-Nets[18]，以及基于Transformer的3D模型如Unet[19]和Swin UNETR [20]。基于这些分割技术，近期研究探索了更具灵活性和可扩展性的架构。

基于Transformer的轻量级架构：随着Transformer在计算机视觉领域的成功应用，研究人员已将其应用于医学图像分割领域，特别是在捕捉长距离空间依赖关系方面[21]。H2Former[22]提出了一种分层混合Transformer架构，而Scribformer[23]则展示了Transformer如何与CNN协同工作以实现弱监督分割。其他创新如GETNet[24]和MedFormer[25]则专注于增强多尺度表征学习能力。与此同时，unetrpt[26]和LDCNet[27]等轻量级架构致力于在降低计算成本的同时保持高精度，这对临床部署至关重要。形状先验正则化[28]进一步提升了解剖一致性。这些主干架构的改进还惠及了更高层次的临床任务，包括病灶定位。

椎体病变检测：精准的病变检测对于识别转移性肿瘤、骨质疏松性骨折及退行性病变等病理状态至关重要。诸如RT-DETR[29]、CAF-YOLO[10]和YOLOv9[30]等检测框架已针对椎体病变的多尺度特征进行优化。联合检测-分类系统（如知识感知框架[9]和动态类别感知融合网络[31]）已应用于多类诊断场景。此外，领域特定研究还涉及骨密度分析[2]、颈椎损伤评估[32]及椎管狭窄量化[33]。鉴于分割、识别与检测的相互关联性，多任务学习已成为极具前景的解决方案。

多任务学习与跨模态方法：多任务学习（MTL）框架旨在联合解决多个目标。通过在单一架构中实现分割、标注和检测，促进跨任务知识共享。近期研究引入了自监督预训练[34]、任务特定注意力模块[15,16]以及跨模态迁移方法以提升泛化能力。基础模型的兴起进一步拓展了这些能力，其中MA-SAM[35]实现了模态无关分割，而零样本泛化技术[36]则支持对未见数据的适应。多标签零样本学习[37]及相关综述

零样本AI[38]凸显了迁移学习在该领域的潜力。尽管这些进展提升了适应性，但真实世界临床应用仍需具备对领域偏移的鲁棒性。

领域泛化与临床部署：领域泛化（DG）已成为跨中心部署自旋分析模型的关键焦点[12]。相关方法包括对抗性领域对齐[13]、形状先验正则化[14]、单源DG[17]以及元学习策略[39]。测试时自适应[40]已被探索用于在无需重新训练的情况下优化预测结果。在实际应用中，计算效率同样重要，如边缘深度学习综述[41,42]和低浮点运算网络[43]所讨论的。近期评估[44]和全自动流程[45]证明了结合准确性、速度和跨域鲁棒性的临床可部署系统的可行性。

总体而言，相关研究揭示了从早期任务特定模型向统一、领域鲁棒且计算高效的框架的清晰演进，这些框架能够以集成方式处理分割、识别和病灶检测。尽管在这些研究方向上都取得了显著进展，但缺乏一个大型、异质性且标注完善的基准数据集，常常限制了公平评估并阻碍了具有强跨领域泛化能力的模型开发。为解决这一空白，我们构建了MultiSpine基准数据集，旨在广泛覆盖多种脊柱区域、成像方案和临床状况。下文将详细阐述本研究采用的数据集组成、预处理流程及标注策略。

2 结果

我们设计了一套全面的实验方案，旨在严格评估VertebraFormer模型的有效性、跨领域泛化能力及可解释性。所有评估均采用统一实验方案，通过MultiSpine基准测试进行，该测试整合了涵盖不同解剖区域、影像学模态和临床场景的多种异构数据集。这种设置不仅能在标准领域条件下全面考察模型性能，还能在模拟真实世界部署的挑战性领域偏移场景中进行深入分析。我们进一步提供定量与定性分析，以验证各架构组件的贡献，并证明预测结果的临床相关性。

2.1 实验装置

所有实验均在PyTorch2.1中完成，运行于配备四块 NVIDIA A100GPU（每块80GB显存）、AMD EPYC7742处理器和512GB内存的工作站，系统运行Ubuntu22.04系统并安装CUDA 12.1。VertebraFormer及所有基线模型均采用相同参数设置进行训练，以确保比较结果的公平性。

数据分割与增强：除非另有说明，MultiSpine基准测试中的每个数据集均按患者级别划分为60%训练集、20%验证集和20%测试集，以避免数据泄露。对于跨域评估，我们采用留一域法，其中四个数据集作为训练源。

剩余数据作为未微调的保留目标。为增强泛化能力，我们采用三维数据增强技术，包括 randomrotation ($\pm 15^\circ$)，scaling ($\pm 10\%$)，translation（最多10个体素）、弹性形变、高斯噪声注入和强度抖动。

训练超参数：模型采用AdamW优化器进行优化，初始学习率为 1×10^{-4} ，权重衰减为 1×10^{-5} ，并采用余弦退火调度器。由于内存限制，3D体数据的批量大小设为2。所有模型均训练300个周期，并基于验证Dice分数进行提前停止。采用最大范数为1.0的梯度剪切技术以稳定训练过程。

评估指标与统计分析：我们采用三项主要指标来评估性能：(1)用于分割准确性的Dice相似系数（Dice）：

$$\text{Dice} = \frac{2|P \cap G|}{|P| + |G|}, \quad (1)$$

其中P和G分别表示预测体素集与真实体素集。(2)识别准确率（ID Acc）用于衡量正确分配椎体ID的比例：

$$\text{ID Acc} = \frac{\text{correctly labelled vertebrae}}{\text{total vertebrae}}. \quad (2)$$

(3)病灶平均精确度（Lesion AP）计算方法为：根据病灶检测置信度评分，通过精确度-召回率曲线下面积得出。

$$\text{AP} = \int_0^1 p(r) dr, \quad (3)$$

其中 $p(r)$ 表示精确度与召回率 r 的函数关系。所有指标均以百分比形式报告。

为量化不确定性，我们通过在每个数据集中重新抽样患者（10,000次重复）计算95%偏差校正加速（BCa）自助法置信区间。除非另有说明，所有报告数值均为均值 $\pm 95\%$ 置信区间（CI）。

VertebraFormer与各任务最强基线之间的两两比较采用双侧Wilcoxon符号秩检验（跨患者），并采用Holm-Bonferroni校正进行多重检验。

2.2 基准比较

为全面评估所提出框架的整体性能，我们在MultiSpine数据集上将VertebraFormer与多种强效方法进行基准测试。评估涵盖临床脊柱分析中三个关键的互补任务：以Dice相似度衡量的椎体分割、以ID准确率表征的椎体识别，以及通过病变AP（病变面积）结合精确率和召回率评估的病变检测。如表1所示的定量结果表明，我们的模型在所有指标上均实现了对竞争性基线的持续改进，同时表现出更小的性能波动。

我们评估了Vertebra Former在本体论中定义的特定病理学类别中的性能表现。如表2所示，该模型表现出高度

表1 MultiSpine基准测试中脊柱CT模型的比较。针对各项指标，我们报告了平均值±95%的BCa自助法置信区间
通过患者层面重采样计算的间隔（10,000次重复）。

方法	分段	识别	病灶检测		
	骰子（%）	IDAcc（%）	精确度（%）	召回率（%）	AP（%）
nnU-Net[7]	77.5±0.4	60.7±2.2	62.4±1.5	58.2±1.5	60.6±1.5
未检测到[19]	88.1±0.3	79.5±1.0	65.8±1.2	64.3±1.2	65.8±1.2
转BTS[46]	88.3±0.3	80.1±1.0	66.4±1.2	64.8±1.2	66.3±1.2
H2Former[22]	88.6±0.3	81.3±0.9	66.9±1.2	65.7±1.2	66.9±1.2
Scribformer[23]	88.7±0.3	82.4±0.9	67.4±1.1	68.2±1.1	67.8±1.1
BLDS[47]	84.4±0.4	70.5±1.6	60.8±1.7	55.3±1.7	57.4±1.7
Dense-U-Net[6]	82.2±0.4	75.6±1.3	58.7±1.9	52.9±1.9	55.4±1.9
VerFormer[48]	83.9±0.3	82.4±0.9	66.3±1.1	67.4±1.1	67.2±1.1
Taoet al.[49]	84.5±0.3	83.3±0.8	65.9±1.2	66.8±1.2	66.2±1.2
VerteFormer[50]	86.0±0.3	84.2±0.7	67.9±1.1	67.4±1.1	67.7±1.1
垂直检测[51]	80.5±0.6	80.6±1.0	58.6±1.9	52.3±1.9	55.2±1.9
脊柱线索[52]	80.3±0.6	80.4±1.0	60.4±1.7	55.6±1.7	57.3±1.7
Ortho2D[53]	78.4±0.7	78.5±1.1	55.4±2.0	50.7±2.0	52.6±2.0
VertNet[54]	82.3±0.5	82.6±0.8	60.5±1.6	58.2±1.6	59.5±1.6
椎体前凸（我们的）	89.3±0.2	85.6±0.6	71.1±1.0	69.0± 0.9	68.7±1.1

对形态学畸形（骨折）具有敏感性，但在细微密度改变（早期溶骨性骨转移）方面存在挑战。

表2 按临床类别分层的病变检出性能指标
报告的指标为每张图像1个假阳性时的平均精度（AP）和灵敏度（Sens@1FP）

病变类别	计数	AP (%)	Sens@1FP	Sens@4FP
骨折（2/3级）	412	78.4±1.5	0.82	0.91
溶组织转移	289	64.2±2.1	0.68	0.79
硬化性转移	156	69.8±2.3	0.73	0.84
感染/糜烂	84	52.1±3.5	0.55	0.67
全面的	941	68.7±1.1	0.72	0.83

感染性病因学的性能下降与标注过程中观察到的低评估者间信度相关（ $k=0.64$ ），这表明标签模糊性导致了模型不确定性。相反，2/3级骨折的稳健检测（AP=78.4%）证实了该模型在识别具有结构学意义的“可操作性”发现方面的有效性。

2.3 跨域泛化

为评估VertebraFormer的域鲁棒性，我们设计了一种零样本跨域评估方案。在每个训练轮次中，模型在四个源域数据上进行训练，并直接在未见过的目标域上进行评估，无需任何微调或域特定适应。该设置模拟了实际部署场景，即模型必须在来自不同扫描仪、机构或患者群体的先前未见过的临床数据上运行。

表3 VertebraFormer在未见数据集上的跨域泛化性能
数值表示Dice评分与ID准确率的均值，附95%BCa置信区间。

目标领域	骰子 (%)	IDAcc (%)
CTSpineLK	86.9±0.5	78.2±1.3
脊柱网	87.5±0.4	80.4±1.1
VerSe 2020	88.1±0.4	81.7±1.0
CSM D	88.4±0.4	81.9±1.0
A型私有股	87.3±0.5	80.1±1.2
私人B	87.8±0.4	80.9±1.1

表4详细说明了留一域评估方案，明确划分了训练集的源域聚合数据及各折1中预留用于零样本推理的目标域。此外，该表还提供了CT体积在实验划分中的定量分布，将样本数量划分为训练集（Ntrain）、验证集（Nval）和测试集（Ntest）三个子集。

表4 保留一个域的排除法协议及每折样本计数。Ntrain与Nval表示源域容积；Ntest表示目标域容积。

目标	来源	N-内酰胺酶	努阿尔	N试验
CT脊椎	脊椎网, VerSe, CSMD, 私有A, 私有B	1005	268	198
脊柱网	CTSpinelK, VerSe, CSMD, 私人A, 私人B	1155	444	128
VerSe 2020	CTSpinelK, SpineWeb, CSMD, A类私人, B类私人	1502	362	103
复合信号多频拨号	CTSpinelK, SpineWeb, VerSe 2020, Private A, Private B	1465	415	50
A型私有股	CTSpinelK, SpineWeb, VerSe 2020, CSMD, Private B	1489	423	42
私人B	CTSpinelK, SpineWeb, VerSe 2020, CSMD, Private A	1459	413	52

MultiSpine基准测试涵盖六个异质性数据集，这些数据集跨越不同解剖区域、采集参数和标记方案（表10），在强度分布、空间分辨率和噪声特征方面引入了显著的分佈偏移。我们在表3中报告了椎体分割的平均Dice分数以及目标域中的识别（ID）准确率。这些指标共同反映了在具有挑战性的跨域条件下，结构描述质量与椎体水平标注正确性的综合表现。

如图1所示，该方法在所有迁移方向上均能持续匹配或超越现有基准模型，且从领域内评估到跨领域评估的性能退化幅度有限。这一表现凸显了动态调制机制与多任务特征对齐机制在缓解领域特定偏差方面的有效性。热力图进一步表明，即使在具有挑战性的迁移场景下——例如在以颈椎数据集为主进行训练、仅在腰椎数据集上进行测试时，VertebraFormer仍能保持具有竞争力的准确率。

2.4 消融研究

为评估VertebraFormer系统中各组件的有效性及其独立贡献，我们开展了一系列消融实验。具体而言，我们将多头识别分支、病灶检测模块和动态调制模块逐步整合到基线UNETR架构中。表5汇总的结果表明，各组件在Dice分数、识别准确率和病灶平均投影（AP）方面均带来显著提升。识别分支大幅提高了解剖标记精度，病灶检测模块则使网络具备定位和表征病理区域的能力。值得注意的是，动态调制模块在所有指标上均展现出最显著的性能提升，这凸显了其在异质性成像条件下优化健康与病变椎体特征表征的作用。




图1 跨域泛化热图。行代表训练数据集，列表示零样本目标域

2.5 复杂度与效率分析

为补充以准确性为导向的评估，我们分析了VertebraFormer的计算复杂度与推理效率，并将其与代表性模型进行比较。

包括 UNETR [19]、H2Former[22]和Scribformer[23]在内的基线模型。Modelcom--复杂度通过可训练参数总数（#参数）和标准 $128 \times 128 \times 128$ 体素输入所计算的浮点运算量（FLOPs）进行量化。推理效率通过测量每秒处理体积数（Vol/s）及在NVIDIA RTX A6000 GPU（48GB显存）上采用混合精度（FP16）执行时的平均体积延迟进行评估[41]。如表6所示，VertebraFormer在模型规模和计算成本方面与Transformer架构[22,23]具有竞争力，同时提供更高精度。这种效率源于轻量级识别分支和动态调制模块内的参数共享[43]。表7进一步显示，该方法达到每秒13.8个体积的吞吐量，可实现脊柱CT扫描的近实时处理[41]。

这些结果表明，VertebraFormer在准确性和计算效率之间达到了良好的平衡，支持典型临床工作负载的近实时处理。

表5 消融研究：各组件对MultiSpine验证集整体性能的贡献度。括号内数值表示相对于先前配置的相对改进。

模型变体Dice (%) IDAcc (%) 病变AP (%)				
 UNETR 基线	88.1	79.5	—	
 +鉴定分支	88.4(+0.3)	83.2(+3.7)	—	
 +病灶检测头	88.5(+0.1)	83.1(-0.1)	65.8	
 +动态调制	89.3(+0.8)	85.6(+2.5)	68.7	

表6 模型复杂度对比（基于 128³input）#参数与浮点运算次数（FLOPs）以百万(M)为单位报告以及每秒千万亿次浮点运算（gigaFLOPs，简称G）[43]。

方法	#参数 (M)	浮点运算次数 (G)	内存 (GB)
nnU-Net[7]	48.0	350.0	12.5
UNETR [19]	92.1	380.5	15.2
经皮BTS[46]	33.4	333.2	12.0
H2Former[22]	102.7	410.3	16.8
Scribformer[23]	88.9	365.7	14.7
Dense-U-Net[6]	55.6	321.4	6.1
陶等 [49]	36.1	299.8	5.2
椎体前凸（我们的）	85.6	342.4	13.9

表7 NVIDIA RTX A6000 GPU（FP16精度）的推理效率对比。吞吐量以每秒处理的3D体数据量（Vol/s）为单位进行 128³inputs，包含所有解码和后处理[41]

方法	伏/秒	延迟/体积（毫秒）
nnU-Net[7]	9.4	106.4
未确定[19]	8.3	120.5
转BTS[46]	10.2	98.0
H2Former [22]	7.8	128.2
Scribformer[23]	8.7	114.9
Dense-U-Net[6]	6.3	157.8
Taoet al. [49]	7.1	140.8
椎体前凸（我们的）	13.8	72.5

2.6 定性可视化

图2展示了一组具有代表性的定性结果，全面展示了VertebraFormer在三个目标任务中的性能表现：椎体分割、识别及病灶检测。每个示例均分为四个面板：(1)提供原始解剖学背景的原始CT切片，(2)叠加椎体ID的真值分割结果，(3)由本模型生成的预测分割掩码及识别标签，(4)对应的病灶检测热力图。

通过视觉对比分析可见，预测生成的分割掩膜与真实标注数据具有高度空间重合性，即便在胸腰椎交界区和退变椎间盘等复杂区域，仍能精准勾勒出椎体边界。该ID分配在整个脊柱范围内保持一致，有效处理椎体可见度不全或形态不规则的病例，这些病例通常对传统方法具有挑战性。

除分割与识别外，病灶检测热图还能通过精确的空间对齐成功定位具有临床意义的异常区域。这些热图可揭示细微的病理模式，如局部皮质变薄、椎体骨折及肿瘤浸润，这些特征在视觉上与正常组织区域明显区分。这种可解释性使放射科医师能够在保留更广泛解剖学背景的同时快速定位异常区域，从而减少诊断模糊性。

值得注意的是，可视化结果还证明了我们的方法对图像质量变化的鲁棒性，包括运动伪影、异质性对比增强以及来自不同设备或机构的扫描间强度不均匀性。预测注释与参考注释之间的强一致性进一步支持了所提出架构在实际部署中的可靠性。




图2 定性可视化结果。(1)CT图像，(2)真实掩膜，(3)预测分割结果，(4)病灶热图。箭头指示T11终板缺损的定位，显示预测病灶热图与真实情况之间的空间对齐。

2.7 动态域调制与推断时间

改编版

我们研究了该模型对领域偏移的鲁棒性以及动态调制策略在测试时的有效性。VertebraForm的默认流程采用

我们采用学习域嵌入技术对网络进行调制，以适应不同CT图像域（扫描仪或数据集差异）。我们比较了以下几种缓解策略：(1)使用随机或交换嵌入（消除已知域代码），以及(2)应用不依赖先验域知识的替代测试时自适应技术，具体包括实例归一化（IN）、自适应实例归一化（AdaIN）和测试时熵最小化（TENT）。我们还通过向域标签注入噪声，量化了性能退化与域误分类率之间的函数关系。表8报告了在这些不同条件下椎体分割的Dice分数、椎体识别（ID）准确率和病灶检测AP值。

表8 域调制与适应性能对比。分割

在不同程度下，默认域嵌入流程的准确度（Dice系数）、椎体识别（ID）准确度及病灶检测AP均被展示。

域标签噪声，以及消融与适应性调整策略。域嵌入

（X%error）表示模型使用了特定领域的调制流程，其中X%的测试案例被错误识别为该领域。随机嵌入与交换

采用完全错误的域代码（按扫描随机分配或在域间系统性交换）对模式I进行嵌入测试。实例归一化

测试时应用；AdaIN=自适应实例归一化；TENT=测试时熵最小化。所有指标均以百分比形式报告。

测试时间法	骰子 (%)	IDAcc (%)	病灶面积百分比 (%)
域嵌入 (0%误差)	90	97	80
域嵌入 (10%误差)	88	96	78
域嵌入 (20%误差)	85	95	75
域嵌入 (30%误差)	82	94	70
Randomembedding (100%error)	75	90	60
交换嵌入 (100%误差)	78	92	65
IN适应	84	93	72
AdaIN自适应	86	94	76
帐篷适应	88	95	78

当提供正确的域嵌入（0%错误率）时，模型在分割和识别性能上表现最佳（平均Dice值 $\approx 90\%$ ，vertebraID准确率97%），同时具备强大的病灶检测能力（AP值80%）。然而，随着域错误分类的增加，模型性能会逐渐下降。当测试集中出现10-30%的域错误时，Dice值从88%降至85% $\rightarrow$ 82%，病灶AP值从78%降至约70%，这表明即使轻微的域错误识别率也会显著影响分割和病灶检测的准确性。椎体识别的鲁棒性稍强（当错误率升至30%时从97%降至94%），这表明除非域不匹配严重，否则模型的识别逻辑仍能保持较高准确率。在最极端的消融实验中，当域嵌入被完全随机化或持续互换时，性能会进一步大幅下降：每张扫描图像使用错误嵌入的情况Dice值 $\approx 75-78\%$ ，病灶AP $\approx 60-65\%$ ，较基线水平显著下降。这些下降证实网络所学习的领域特异性调制至关重要，但输入的领域编码存在错误。




图3 VertebraFormer在合成扰动下的性能表现（按解剖区域划分）。我们报告了各脊柱区域在基线状态及不同输入降质条件下的平均分割结果：(a) Dice分数（%）、(b) 椎体ID准确率（%）及(c) 病变检测AP（%）。括号内为95%置信区间（自助法）。强度 $\pm 15\%$ 和 $\pm 30\%$ 表示HU值线性缩放 $\pm 15\%$ 和 $\pm 30\%$ 。噪声 σ 表示HU值中标准差为 σ 的加性高斯噪声。3mm/5mm层厚为重建切片。金属伪影表示模拟骨科硬件存在及条纹状伪影。

破坏特征归一化层和注意力层，导致椎体及病变漏检。

相比之下，自适应测试时间方法（表8下排）对领域偏移表现出更强的适应能力。无需任何领域标识符，TENT自适应方法即可实现约88%的Dice值和95%的ID准确率，几乎与无误差基线持平。

这表明在线熵最小化技术能有效调整模型以适应目标数据分布，在领域标签不可靠时可恢复大部分性能损失。AdaIN通过动态对齐测试扫描的强度统计量与源域，同样表现优异（Dice值86%，AP值76%），优于简单的实例归一化方法（Dice值84%）。值得注意的是，即使采用即时特征通道标准化的IN策略，其分割Dice值仍比朴素随机嵌入方案提升2-3个百分点，表明某种形式的即时领域适应具有优势。在所有方法中，默认管道在正确领域信息下仍能获得最高准确率。然而，TENT与完全知情模型的接近平分（Dice值88% vs. 90%）表明，当领域标签缺失或易出错时，测试时训练作为稳健替代方案的价值。

2.8 输入扰动鲁棒性

我们通过消融实验评估模型在不同图像扰动下的鲁棒性，模拟潜在的真实世界变异性。所有测试均采用MultiSpine数据集（涵盖颈椎、胸椎和腰椎区域），并评估分割重叠度（Dice）、解剖学识别准确率（ID Acc）以及病灶检测平均精度（Lesion AP）。图3按脊柱区域分类，总结了各扰动条件下的性能下降情况。无干扰状态下的基线表现较高（Dice 88-90%，ID Acc 84-87%，AP 65-70%（视区域而定））。我们报告的均为均值指标及其95%置信区间。

VertebraFormer对中等强度的噪声干扰表现出较强的抗扰性，在实际变化条件下仍能保持较高的识别准确率。显著的性能下降仅在严重失真情况下发生。由于模型具备跨域通用特性，各厂商特定子域间的数据退化程度通常较为均匀，即不存在特定扫描仪数据的异常脆弱性。然而，某些域在扰动响应中确实表现出轻微差异。值得注意的是，该模型的软件架构设计即使在扰动情况下仍能保持解剖学一致性。我们观察到扰动下的识别错误通常仅限于个别错误（如漏标椎骨），而非整个序列的混乱性误标。这表明该模型仍能利用全局脊柱上下文保持正确轨迹，而传统逐层切片方法可能缺乏这一特性。这些压力测试突显了需谨慎处理的场景：极度嘈杂或低分辨率扫描，以及金属硬件的存在，均可能导致性能下降，此时额外的训练或预处理将具有显著益处。

2.9 统一模型与模块化流水线

VertebraFormer的核心动机是用单一统一模型替代多阶段流程。为量化其优势，我们在固定延迟预算下对VertebraFormer与等效三模型流程进行了模拟对比。该流程包含三个核心组件：(1) 三维 UNETR 分割网络用于分割椎骨，(2) 三维 ResNet分类器为每个分割后的椎骨标注解剖学标签，(3) 受YOLOv5启发的检测器用于定位病灶（将每个椎骨区域视为病灶的潜在边界框）。若采用完整架构，该流程的运行速度和内存占用将显著高于VertebraFormer——例如，仅 UNETR 组件就拥有约9200万参数，且在A6000架构上每个体素的推理时间达120毫秒，若再增加两个网络组件，延迟和内存消耗将进一步增加。为确保公平比较，我们通过降维或优化各组件，使流程运行时间与VertebraFormer保持一致（在A6000架构上每个体素约72毫秒）。具体而言，我们将分割输入分辨率降低约50%（以加快 UNETR 速度），采用轻量级ResNet-18对裁剪后的椎体图像进行分类，并将病灶检测器限制为仅评估高概率区域的候选区域（而非全密度扫描）。这些调整使流程总处理时间缩短至约75毫秒（与统一模型相比误差在5%以内），但代价是部分准确度的损失。表9展示了在该等延迟设置下统一模型与流水线的性能对比。

3 讨论

本研究提出VertebraFormer框架，这是一个统一的Transformer架构，可同时实现脊柱CT扫描中椎体分割、解剖结构识别及病灶检测。为进行全面评估，我们通过整合和统一涵盖颈椎、胸椎及腰椎区域的六种不同数据集，构建了MultiSpine基准测试集，从而捕捉影像学协议、解剖形态及临床状况在不同领域间的显著差异。

表9 统一模型对比 等效三模型流水线（匹配延迟）
VertebraFormer与模块化流程进行对比（U-Net用于分割，ResNet分类器用于识别）
基于YOLO的病灶检测器）。在 RTX A6000上，总运行时间被限制为72毫秒（by
缩减管道模型规模/分辨率）。指标在MultiSpine测试集上。统一方法在所有任务上均获得
更高准确率。内存为GPU峰值使用量。置信区间（95%CI）
指标显示

方法	分割骰	ID准确性	AP病变	潜伏期 (A6000)	峰值存储器
VertebraFormer (一体化)	89.3% (±0.2)	85.6% (±0.6)	68.7% (±1.1)	约72毫秒	约13.9 GB
3-模型管 道	86.5% (±0.4)	81.0% (±0.8)	60.5% (±1.2)	约75毫秒	约15.8 GB

通过大量实验验证，我们证明VertebraFormer在所有三个任务中均能持续超越强基线模型，无论是在领域内还是具有挑战性的跨领域场景中均表现优异。提出的动态调制机制与识别分支提升了解剖一致性及领域转换下的鲁棒性，而病灶检测模块则提供了可解释且具有临床意义的病理区域定位。消融研究证实了各架构组件的贡献，复杂度分析表明该方法在多任务设计下仍能实现具有竞争力的推理效率。

重要的是，定性可视化结果表明，该框架能够生成解剖学上精确的预测结果，并提供清晰的病灶热图，为放射科医师提供了实用价值，使其能够高效评估脊柱病变。这些发现凸显了VertebraFormer作为自动化、多维度脊柱图像分析工具的潜力，但在常规临床应用前仍需进一步前瞻性验证。

展望未来，该框架可进一步扩展以利用多模态成像（如MRI+CT），整合患者特异性临床元数据，并适应其他脊柱疾病（如脊柱侧凸或退行性椎间盘疾病）。我们相信，此类进展将进一步提升多任务学习在脊柱影像分析中的泛化能力，并拓宽其临床应用价值。

局限性与未来研究：尽管VertebraFormer在MultiSpine基准测试中表现优异，并展现出良好的跨域泛化能力，但仍存在若干局限性。

首先，尽管MultiSpine数据集整合了六种异质性数据源，但在罕见病理状况、极端影像伪影、过渡椎体、广泛植入物及儿科病例的覆盖范围上仍存在局限性。这可能限制模型对高度非典型解剖结构或采用非常规扫描方案获取的影像的泛化能力。纳入更多数据集（尤其是包含罕见疾病和多样化患者群体的数据集）将进一步提升模型的稳健性。

其次，现有框架仅基于CT数据进行训练。在临床实践中，多模态成像（如MRI或PET-CT）可提供互补的结构与功能信息，从而增强解剖学识别的准确性。

将该框架扩展至联合处理多模态数据仍是未来研究的重要方向。

第三，尽管多任务学习范式能够同时优化分割、识别和病灶检测，但当病理特征与解剖边界重叠时，可能会出现任务干扰，导致任一任务出现细微误差。采用自适应任务加权或不确定性感知的损失平衡机制，可有效缓解此类冲突。

最终，该评估主要针对已获取扫描数据的回顾性数据集。为全面评估部署可行性，需开展真实世界临床工作流程中的前瞻性研究——包括实时推理、放射科医师的交互式优化以及与医院PACS系统的整合。

在后续工作中，我们计划：(1)通过多中心协作获取罕见及具有挑战性的病例以丰富数据集；(2)扩展架构以支持多模态三维成像；(3)探索元学习与持续学习策略以实现快速领域适应；(4)整合临床元数据与患者病史以支持更具情境感知性的诊断预测。我们相信，解决这些局限性将进一步提升VertebraFormer的临床适用性与泛化能力。

4 方法

4.1 数据集与预处理

为全面评估椎体分割、识别及病变检测模型在不同临床条件下的泛化能力，我们通过整合六组异质性脊柱CT数据集构建了MultiSpine基准测试集。这些数据集涵盖颈椎、胸椎和腰椎等不同解剖区域，采用多种扫描方案、不同厂商设备及临床场景采集。这种多样性确保了对广泛解剖变异、对比度分布及病理表现的覆盖，使该基准集适用于多领域训练、跨领域评估及零样本迁移实验。

表10总结了数据集的关键特征。公共数据集如CTSpinelK、SpineWeb、VerSe 2020及多模态CSMD提供开放存取数据集，而机构特定数据集（Private A和Private B）在使用前需经机构审查委员会（IRB）批准并进行匿名化处理。我们特别纳入CSMD以展示MRI模态（T1/T2）与标准CT数据的对比。病变标注仅适用于VerSe 2020和Private B数据集，其中由委员会认证的放射科医师标注了椎体骨折、转移性病灶及退行性改变；其余数据集（包括CSMD）则采用椎体掩模和ID标识，不标注病变。这些数据集中，颈椎扫描通常显示椎体较小、间距较密且皮质较薄；胸椎扫描呈现肋骨关节结构及较窄的椎管；腰椎扫描则包含较大椎体、更显著的椎弓根及较厚的皮质结构。

在模型训练前，所有扫描数据均需经过统一的预处理流程。椎体覆盖不完整、存在严重运动伪影或金属伪影的体积数据将被排除。

表10 MultiSpine基准测试中各组成数据集的汇总。大多数数据集由CT扫描构成，而 CSMD 则引入了多模态数据（CT+MRI）。分辨率以x×y×z轴顺序给出。“扫描（训练集/验证集/测试集）”列出了每个分割的患者层面体积。

数据集	地区	扫描 (Tr/Val/Te)	分辨率 (mm ³)	注释	许可证
CTSpine1K[8]	颈的	1005 (610/197/198)	混合的	口罩, ID	平民
脊椎网[55]	腰椎	609 (460/21/128)	0.6×0.6×2.0	掩码	平民
VerSe2020[4]	所有	319 (113/103/103)	混合的	口罩、身份证、Lmk	平民
CSMD [56]	颈的	250 (总计)	混合的	标签, 口罩	平民
A型私有股	胸部的	210 (126/42/42)	0.75×0.75×1.5	掩码	工业基准
私人B	腰椎	260 (156/52/52)	0.7×0.7×1.0	口罩, ID	内部的

每次扫描均被重采样至各向同性分辨率1.0 mm³，强度值以亨氏单位（Hounsfield units）为单位，被截断至[-1000,1000]范围，并线性归一化至[0,1]。所有椎体掩模均采用统一的解剖学ID编码方案，覆盖C1-C7、T1-T12和L1-L5，确保数据集间标签一致性。此外，通过刚性对齐标准化患者在轴位面的体位。

为增强模型对领域变异的鲁棒性，我们在训练过程中应用了一系列3D数据增强技术，包括随机旋转、缩放、弹性变形、强度扰动和随机裁剪。这些增强技术模拟了不同机构间患者体位、扫描仪校准及视野的差异。

MultiSpine的多样性如图4所示，该图展示了从VertebraFormer编码器主干（使用预训练权重初始化）中提取的潜在特征的s at-SNE投影。对应不同解剖区域和数据集的显著聚类表明，风格、对比度和空间结构存在明显的跨域偏移。图5展示了来自颈椎、胸椎和腰椎区域的代表性轴向CT切片，突显了挑战跨域泛化的解剖学差异。

为评估目的，每个数据集在患者层面被划分为60%的训练集、20%的验证集和20%的测试集以防止数据泄露。在跨域实验中，我们采用第4.1节所述的留一域外法（leave-one-domain-out protocol），在多个源数据集上进行训练，并在未见过的目标域上进行测试。该设置模拟了真实的临床部署场景，即模型必须在无标注目标样本的新数据分布上运行。

4.2 数据集整理与严格去重

为构建MultiSpine基准，我们整合了四个公开数据源（CTSpine1K、SpineWeb、VerSe2020、CSMD）和两个私有机构队列的CT扫描数据。鉴于这些数据源的异质性，我们实施了严格的三阶段审核流程，以防止数据泄露并确保严格的分割卫生标准。

我们认识到开源数据集中的患者重叠代表了一种重要风险。为解决这一问题，我们采用了双重验证策略。首先，对于DICOM




图4 t-SNE可视化展示了MultiSpine中各领域特征分布。每种颜色代表一个独特的解剖区域。




图5 MultiSpine系统中颈椎、胸椎及腰椎区域的代表性轴位CT切片。

在 UID 追踪过程中，我们提取了可用的研究实例 UID（0020,000D）和系列实例 UID（0020,000E）。任何共享研究实例 UID 的体积数据被归类为单个患者事件，并被分配至数据划分的某一类别（训练集、验证集或测试集）。其次，在感知哈希（pHash）分析中，我们旨在检测近乎重复的扫描数据，包括那些除在匿名化过程中引入的重采样、裁剪或窗口/层面变化外完全相同的体积数据。我们采用ablock-mean哈希算法对所有扫描体积的中央50层进行三维感知哈希计算，将汉明距离 ≤ 5 的配对标记为需人工放射学复核。

本次审计发现VerSe 2020训练集与CTSpinelK测试集之间存在43个重叠卷，这些重叠卷此前未被记录。为确保测试评估的完整性，已将这些重复卷从训练集中移除。

我们还在私人队列中发现了12例患者重叠病例，这些病例源于同一患者在术前和术后接受扫描；这些病例被归类以确保所有分组间严格保持患者层面的独立性。

经过数据整理后，完整数据集采用分层抽样策略划分为训练集（60%）、验证集（20%）和测试集（20%）。分层依据供应商/扫描仪特性进行，以确保测试集能涵盖扫描仪相关偏倚的代表性分布（如GE、Siemens、Philips），从而避免对扫描仪特异性噪声特征的过拟合。分层同时基于病理严重程度，包括金属伪影和严重畸形（Cobbangle $>20^\circ$ ）的存在，以确保测试集能充分挑战模型的鲁棒性。

全程实施严格的患者级别隔离：同一患者ID的所有扫描数据，无论时间点和模式如何，均被限制在单一文件夹内。为确保无泄漏现象，我们额外在最终测试集与训练集之间进行了最近邻像素分析，确认未残留任何重建级别的重复像素。

4.3方法:VertebraFormer网络

我们提出VertebraFormer框架，这是一个统一的多任务Transformer架构，可同步解决脊柱影像分析中的三大核心挑战：椎体分割、解剖结构识别与病灶检测。该方法的灵感源自临床实践中的现实情况——这些任务本质上是相互关联的：精准的解剖结构识别依赖于精确的分割边界，而病灶检测则需要空间定位与解剖背景的双重支持。我们摒弃将这些任务视为独立问题的思路，设计了一个统一架构，通过共享表征来提升所有任务的性能，同时保持适用于临床部署的计算效率。

4.4 架构设计与概述

VertebraFormer架构体现了三个基本设计原则，这些原则针对多域脊柱图像分析的独特挑战。首先，全局




图6 所提VertebraFormer的整体架构。其由一个Transformer构成编码器、多任务解码头及动态调制模块。

上下文感知认识到椎体结构在整个脊柱中呈现强烈的空间关联性，其中单个椎体的身份和边界最好通过其邻近椎体的关系来理解。其次，任务协同性承认分割、识别和病灶检测是互补任务，可通过共享特征学习相互强化。第三，域适应性确保了在真实临床实践中遇到的异质性成像条件下稳健的性能表现。

我们的架构由四个协同工作的核心组件构成：基于变压器的编码器可捕捉整个脊柱的长程空间依赖关系；专门设计的多任务解码头在保持一致性的同时生成任务特定输出；动态调制机制可根据成像特征变化进行自适应调整；以及精心设计的训练目标以平衡不同任务需求。编码器通过基于补丁的分词处理三维输入体积，随后经过自注意力层，使模型能够捕捉理解脊柱结构所需的全局解剖关系。共享主干网络的表征随后由三个专用解码分支处理：具有跳跃连接的分层分割解码器用于精确边界勾画、基于区域的解剖标记分类器以及用于病理定位的关键点式病灶检测器。

动态调制机制作为共享编码器与任务特定解码器之间的桥梁，能够根据成像特征自适应调整特征表示。该设计使模型在不同临床场景中保持高性能，同时保留统一多任务学习的优势。完整架构如图6所示。

4.5 基于变压器的编码器架构

本方法的基础在于有效对三维医学体数据进行分词处理，以便进行Transformer模型处理。给定一个 n 输入体 $I \in \mathbb{R}^{H \times W \times D}$ 我们将它分割成 size P^3 的非重叠立方体块，从而形成一系列 $N = \frac{HWD}{P^3}$ 小块 将每个斑块 $\mathbf{p}_i \in \mathbb{R}^{P^3}$ 进行平坦化处理并线性投影，生成斑块嵌入向量 $\mathbf{e}_i \in \mathbb{R}^d$ 模型：

$$\mathbf{e}_i = \text{线性}(\text{展平}(\mathbf{p}_i)) + \text{位置}(4)$$

其中， pos_i 表示可学习的三维位置编码，其保留了对解剖学理解至关重要的空间关系。选择的补丁尺寸 P 体现了计算效率与空间分辨率之间的关键权衡——较大的补丁会缩短序列长度，但可能丢失精确边界划分所需的精细细节。

补丁嵌入通过 L 个Transformer层进行处理，每个层由多头自注意力（MHSA）和前馈网络（FFN）构成。自注意力机制在脊柱图像分析中展现出显著优势，因其能自然捕捉表征椎体关系的长程依赖性：

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right)V \quad (5)$$

其中 Q 、 K 和 V 分别为查询矩阵、键矩阵和值矩阵。该模型架构可直接关联来自远端脊柱区域的病灶，即使存在病理改变或影像伪影，仍能实现椎体边界的稳健识别。

我们的编码器通过从中间变压器层提取多尺度特征表示来生成多尺度特征表征。 $\{\frac{1}{4}, \frac{1}{8}, \frac{1}{16}\}$ 这些层级特征具有双重功能：既为分割解码器提供跳过连接以保留精细空间细节，又为识别与病灶检测任务提供多尺度上下文。多尺度设计基于脊柱分析不同环节对空间抽象层次的差异性需求——分割任务需要精细细节，而识别任务则更依赖宏观解剖学背景。

4.6 多任务解码头

该分割解码器采用分层上采样策略，通过整合Transformer编码器的多尺度特征，逐步重建空间分辨率。解码器由四个上采样模块组成，每个模块的分辨率均翻倍。

通过转置卷积实现空间分辨率提升，同时将通道维度减半：

$$F(l+1) = \text{Up}(F(l)) + \text{Conv}(\text{Skip}(l)) \quad (6)$$

其中 $F(l)$ 表示第 l 层的特征， $\text{Skip}(l)$ 表示来自对应编码器层的跳跃连接。该设计确保在编码过程中丢失的精细空间信息能在解码时被恢复，这对准确勾画椎体边界至关重要。最终的分割输出采用混合预测策略，既能生成二值椎体掩码，又能生成多类语义标签，使模型在保持整体结构连贯性的同时，能够区分单个椎体。

椎体识别在实例级别进行，将每个分段的椎体区域分类为解剖学类别。我们的方法利用三维感兴趣区域对齐（RoIAlign）操作，从可变大小的椎体区域中提取固定尺寸的特征表示：

$$\text{froi} = \text{RoIAlign}(\text{Fenc}, \text{bbox}_i) \quad (7)$$

其中 Fenc 表示编码特征， bbox_i 表示第 i 个椎体区域的边界框。RoIAlign操作确保在特征提取过程中保留空间信息，这对于维持不同椎体类型所特有的几何关系至关重要。提取的区域特征通过多层分类器进行处理，该分类器将几何和上下文信息映射到跨越C1-C7、T1-T12和L1-L5的解剖学标签，并采用跨域共享参数以确保识别标准的一致性。

该病灶检测模块采用中心点检测范式，通过预测学习热图中的局部最大值来确定病灶位置。该方法特别适用于椎体病变检测，这类病变常表现为细微且形态不规则的异常结构，而刚性三维边界框难以准确捕捉。检测模块生成三个互补输出：分类热图 $H \in \mathbb{R}^{C \times H \times W \times D}$ 用于指示各空间位置的病灶概率；回归偏移量 $O \in \mathbb{R}^3 \times H \times W \times D$ 实现精准中心定位；尺寸估计值 $S \in \mathbb{R}^3 \times H \times W \times D$ 用于病灶范围预测。

$$H, O, S = \text{DetectionHead}(\text{Fenc}). \quad (8)$$

训练过程中，每个标注病灶（骨折、转移性沉积或退行性病变）均被映射至最近的特征网格位置，围绕该位置放置半径为 r 的三维高斯核，其中 r 的选取依据病灶范围及体素间距。当高斯值超过阈值 T_{Pos} 时，对应 H 类通道的体素被判定为阳性，而相邻体素则被弱化处理。

偏移量 O 作为离散网格位置与连续病灶中心之间的残差进行回归分析，而 S 则对沿三个空间轴的对数尺度病灶宽度进行回归分析。

仅VerSe 2020和Private B的扫描数据包含病灶标注；其余数据集仅用于分割和识别。

在推理阶段，通过将热图中的 H 值设定为 `confidencelevel0` 阈值，并应用固定半径的三维非极大值抑制技术，从而从热图中提取局部最大值。

物理空间（5毫米）。每个存活的最大病灶生成一个候选病灶，其中心坐标为 $J_{grid}+O(x_{grid})$ ，大小为 $S(x_{grid})$ 。通过匈牙利算法将预测病灶与真实病灶匹配，采用三维交并比（ $IoU \geq 0.3$ ）和中心距离（ ≤ 5 毫米）的综合标准。根据所得精确率-召回率曲线计算各病灶类别的平均精度，随后对各类别进行宏平均。

4.7 动态调节机制

临床CT影像在不同机构、扫描仪制造商及采集协议间存在显著差异。这些差异表现为强度分布、噪声特征、空间分辨率及对比度模式的差异，可能显著影响模型性能。传统域适应方法在训练或微调阶段需访问目标域数据，这限制了其在临床部署场景中的适用性。

我们的动态调制机制通过学习根据成像特性自适应调整特征表示来应对这一挑战。动态调制模块作用于中间变换器特征，应用基于领域特定嵌入的已学习变换。给定编码特征 $F \in \mathbb{R}^{N \times d}$ 和领域嵌入 $ea \in \mathbb{R}^d$ ，该模块可生成通道级和空间级注意力图：

$$\alpha_c = \text{sigmoid}(\text{FCe}(ea)) \quad (9)$$

$$\alpha_s = \text{sigmoid}(\text{Conv}_s(\text{reshape}(ea))) \quad (10)$$

调制特征的计算公式为：




图7 动态调制模块。 基于输入模态调节变压器特性信号（CT/MRI）。该机制促进了表12中评估的跨模态适应。

$$F_{mod} = F \odot (\alpha_c \otimes 1_n) \odot \text{广播}(\alpha_s) \quad (11)$$

其中 $\odot$ 表示元素乘法， $\otimes$ 表示外积。该表述形式使模型能够选择性地强调通道和空间区域。

这些内容对每种特定影像学情境最具信息价值。图7展示了该组件的结构。

领域嵌入通过对比学习方法实现，该方法在鼓励同一领域内扫描图像生成相似嵌入的同时，促进不同领域间的多样性。训练过程中，我们从多个领域中抽取包含扫描图像的微批次，并优化嵌入空间：

$$\mathcal{L}_{domain} = -\log \frac{\exp(\text{sim}(e_i, e_j^+)/\tau)}{\sum_k \exp(\text{sim}(e_i, e_k)/\tau)}, \quad (12)$$

在哪里 e_j^+ 该示例代表同一领域的正例，其中T为温度参数。推理阶段不更新模型参数，而是采用与编码器联合训练的轻量级领域分类器 $g(-)$ ，通过其预测源域概率向量 $p(d|I) = g(I)$ 。有效领域嵌入由源域原型的凸组合构成。

(13)

$$e_d^* = \sum p(d|I) e_d,$$

该特征随后被输入动态调制模块。算法1中的InferDomain(I)函数对应这种前馈式处理流程。因此我们认为VertebraFormer在测试阶段采用的是基于域特征的调制机制，而非模型权重的迭代式测试时自适应调整。

4.8 培训目标与优化

整体训练目标通过精心设计的权重方案将任务特异性损失相结合：

$$L_{total} = \lambda_{seg} L_{seg} + \lambda_{id} L_{id} + \lambda_{det} L_{det} + \lambda_{domain} L_{domain} \quad (14)$$

其中 λ_{seg} 、 λ_{id} 、 λ_{det} 和 λ_{domain} 是任务特定的权重因子，分别通过经验设定为1.0、0.5、0.5和0.1。

该分割损失采用混合公式，结合Dice损失函数用于最大化重叠区域，以及焦点交叉熵用于边界细化：

$$L_{seg} = L_{dice} + \alpha L_{focal} \quad (15)$$

Dice损失函数促使预测掩膜与真实掩膜之间产生全局重叠：

$$\mathcal{L}_{dice} = 1 - \frac{2 \sum_i p_i g_i + \epsilon}{\sum_i p_i + \sum_i g_i + \epsilon} \quad (16)$$

其中 p_i 和 g_i 分别表示体素 i 处的预测概率和真实概率。焦点损失组件通过降低简单样本的权重来解决类别不平衡问题。若无特别说明，分割分支的权重设为0.5，采用标准聚焦公式，聚焦参数 $\gamma = 2.0$ ，类别平衡 $\text{factor}_{cls} = 0.25$ 。

该识别损失函数结合了标准交叉熵分类与空间一致性约束，以确保解剖学合理性：

$$L_{id}=Cce+\beta L_{consistency} \quad (17)$$

该病灶检测损失通过结合用于中心点预测的局灶损失与用于偏移回归的平滑L1损失，解决了检测细微、不规则形态病理结构的挑战：

$$\mathcal{L}_{det} = \mathcal{L}_{focal}^{det} + \lambda_{reg} \mathcal{L}_{reg}, \quad (18)$$

在哪里 $\mathcal{L}_{focal}^{det}$ 采用与分割分支相同的 (Y, Qcls) 参数，且 $\lambda_{reg}=1.0$ 。模型训练采用两阶段课程体系，逐步引入任务

复杂度。在前100个训练周期中，我们仅使用分割训练VertebraFormer ($\lambda_{seg}=1.0$, $\lambda_{id}=\lambda_{det}=0$) 并采用域对比正则化 ($\lambda_{domain}=0.1$)，以建立基础解剖学理解。随后50个周期中，我们线性 ramp λ_{id} and λ_{det} 从0到0.5，同时 keeping λ_{seg} 保持固定，之后所有权重在剩余150个周期中保持不变。该训练方案可避免任务早期干扰，并促使模型发展出稳健的共享表征。

数据增强技术在提升各类成像条件下的鲁棒性方面具有关键作用。我们的增强策略包含空间变换（旋转、缩放、平移）、强度调控（亮度、对比度、噪声注入）以及模拟解剖变异的弹性变形。所有任务标签均统一应用增强技术以保持空间对应关系。

训练采用AdamW优化器，初始学习率 $lr=1\times 10^{-4}$ ，权重衰减 $wd=1\times 10^{-5}$ ，并采用余弦退火调度。模型训练300个周期，基于验证性能进行提前停止。最大范数为1.0的梯度裁剪稳定了训练过程，这对于复杂多任务目标景观尤为重要。

4.9 实施与实验验证

VertebraFormer框架的实现旨在高效处理跨不同影像领域的多任务学习。我们的实现策略侧重于计算效率、内存优化以及可部署于临床环境的可重复训练流程。

计算复杂度分析表明，由于自注意力操作的二次特性，VertebraFormer 的复杂度 $O(N^2d + Nd^2)$ 随 N 增加而呈线性增长。

$\frac{HWD}{P^3}$ represents 其中s为序列长度，d为嵌入维度。对于标准输入体积 of 128^3 voxels with 8^3 patches，可生成长度为 $N=4096$ 的序列，该长度在现代GPU上仍具有计算可行性，只要配备足够内存即可处理。多任务解码仅需额外运算量不足5% (FLOPs)，因所有解码头共享相同编码表征；动态调制虽能显著提升跨域性能，但其运算复杂度仅占总操作量的不到1%。

内存优化策略包括：对中间激活值进行梯度检查点保存、采用FP16计算的混合精度训练，以及基于GPU可用内存的自适应批量大小调整。该框架通过数据并行性支持跨多GPU分布式训练，可高效扩展至更大规模数据集并实现更快收敛。

算法1: VertebraFormer训练与推理流程输入: 三维输入体数据 $I \in RH \times W \times D$, 模态/域标签 $d \in D$

输出: 分割掩膜 S 、椎体ID预测 Y_{id} 、病灶检测 y_{det}

1 训练阶段: 对 $b=1$ 至 B (小批量) 进行

对于所有 $i \in b$, 执行以下操作:

// 补丁分词与Transformer编码 $P_i \leftarrow \text{分词}(I_i, \text{补丁大小} = P^3)$;

$E_i \leftarrow P \cdot \text{Wembed} + \text{PosEnc}(P_i)$;

$F_i \leftarrow \text{TransformerEncode}(E_i)$;

// 基于域嵌入的动态调制

$e_d \leftarrow \text{DomainEmbed}(d_i)$;

$F_i^{\text{mod}} \leftarrow \text{DynamicModulate}(F_i^{(L)}, e_d)$;

多任务解码

$S_i \leftarrow \text{SegmentationDecoder}(F_i^{\text{mod}}, F_i^{(1:L-1)})$;

$\text{bbox}_i \leftarrow \text{ExtractBBox}(S_i)$;

$f_{\text{roi}} \leftarrow \text{RoIAlign}(F_i^{\text{mod}}, \text{bbox}_i)$;

$Y_i^{\text{id}} \leftarrow \text{IdentificationHead}(f_{\text{roi}})$;

$Y_i^{\text{det}} \leftarrow \text{LesionDetectionHead}(F_i^{\text{mod}})$;

// 损失计算

$\mathcal{L}_{\text{seg}}^{(i)} \leftarrow \text{DiceLoss}(S_i, S_i^{\text{gt}}) + \alpha \text{FocalLoss}(S_i, S_i^{\text{gt}})$;

$\mathcal{L}_{\text{id}}^{(i)} \leftarrow \text{CrossEntropy}(Y_i^{\text{id}}, Y_i^{\text{id,gt}}) + \lambda_{\text{cons}} \mathcal{L}_{\text{consistency}}$;

$\mathcal{L}_{\text{det}}^{(i)} \leftarrow \text{FocalLoss}(Y_i^{\text{det}}, Y_i^{\text{det,gt}}) + \lambda_{\text{reg}} \text{L1Loss}$;

$\mathcal{L}_{\text{domain}}^{(i)} \leftarrow \text{ContrastiveLoss}(e_d, \mathcal{E}_d)$;

最后部分

// 批量聚合与优化

$\mathcal{L}_{\text{total}} \leftarrow \frac{1}{|b|} \sum_{i \in b} [\lambda_{\text{seg}} \mathcal{L}_{\text{seg}}^{(i)} + \lambda_{\text{id}} \mathcal{L}_{\text{id}}^{(i)} + \lambda_{\text{det}} \mathcal{L}_{\text{det}}^{(i)} + \lambda_{\text{domain}} \mathcal{L}_{\text{domain}}^{(i)}]$;

$\theta \leftarrow \eta \cdot \text{ClipGrad}(\text{时域}, \mathcal{L}_{\text{total}}, \text{最大范数}=1.0)$;

20 端

21 推理阶段:

22 $P \leftarrow \text{分词处理}(I, \text{patch_size} = P^3)$;

23 $E \leftarrow P \cdot \text{Wembed} + \text{PosEnc}(P)$;

24 $F(1:L) \leftarrow \text{TransformerEncode}(E)$;

25 $e_a \leftarrow \text{下界域}(I)$;

26 $F^{\text{mod}} \leftarrow \text{DynamicModulate}(F(L), e_a)$;

27 $S \leftarrow \text{SegmentationDecoder}(F^{\text{mod}}, F(1:L-1))$;

28 $\text{bbox} \leftarrow \text{ExtractBBox}(S)$;

29 $f_{\text{roi}} \leftarrow \text{RoIAlign}(F^{\text{mod}}, \text{bbox})$;

30 $Y_{\text{id}} \leftarrow \text{IdentificationHead}(f_{\text{roi}})$;

31 $Y_{\text{det}} \leftarrow \text{LesionDetectionHead}(F^{\text{mod}})$;

32 返回 $S, Y_{\text{id}}, Y_{\text{det}}$

我们的全面实验验证通过系统性消融研究证明了各架构组件的有效性。表11展示了逐步添加多任务头和领域适应机制所实现的渐进式改进。结果明确显示，动态调制在所有指标上均带来最显著的性能提升，与基线配置相比，Dice分数提升+1.2%、识别准确率提升+2.5%、病灶检测AP值提升+2.9%。

表12中的跨域评估结果验证了我们动态调制方法在处理域偏移方面的有效性。MRI性能的显著提升（Dice评分从77.2%提升至82.3%）证明了该机制无需领域特定微调即可适应不同成像特征的能力。这种能力对于临床部署至关重要，因为模型必须在多种扫描仪类型和成像协议中可靠运行。

通过表6和表7的参数设置进行的额外效率分析证实，尽管采用多任务架构，VertebraFormer仍保持具有竞争力的计算需求。虽然参数数量略高于单任务基线（约1.01亿个参数 vs UNETR 的9700万个），但统一框架消除了对多个专用模型的需求，从而实现整体内存节省和简化部署流程。在 RTX A6000上测得的13.8卷/秒吞吐量，使得需要快速诊断支持的临床工作流程能够实现近乎实时处理。

表11 VertebraFormer组件在MultiSpine验证集上的消融研究

逐步增加组件的使用在所有指标上均显示出持续改善。UNETR [19]作为比较的基线。

配置	分割+识别			病灶检测	
	骰子 (%)	IDAcc (%)	mIoU	骰子 (%)	IDAcc (%) LesionAP (%)
UNETR 基线[19]	88.1	79.5	72.4	—	—
+多头ID分支[15]	88.4	83.2	74.6	—	—
+病灶检测头[16]	88.5	83.1	74.5	88.5	83.1 65.8
+动态调制[13]	89.3	85.6	76.1	89.3	85.6 68.7

表12 跨模态性能评估证实了动态方法的有效性

无需在训练过程中获取目标域数据的域适应调制[12,14]。

模型配置	CT密度积分 (%)	MRIDice (%)	Avg. IDAcc (%)
UNETR (共享权重) [19]	88.6	77.2	80.3
无调制的Ours	89.1	79.5	82.1
Ours w/调制[40]	89.4	82.3	84.2

4.10 伦理声明

本研究遵循《赫尔辛基宣言》开展，并获得所有参与机构的机构审查委员会（IRB）批准。

对于公开数据集（CTSpinelK、SpineWeb、VerSe 2020），原始提供方在发布前已对所有数据进行完全匿名化处理，无需额外伦理审批。针对私有数据集（Private A和Private B），已获得机构伦理批准，并通过标准化去标识化程序移除所有患者标识符，确保符合《健康保险可携性和责任法案》（HIPAA）及相关国家隐私法规。模型开发与评估过程中未使用任何个人可识别信息（PII）或受保护健康信息（PHI）。本研究仅涉及匿名化医学影像的回顾性分析，根据当地机构审查委员会（IRB）指南无需获取知情同意。

声明语句

临床试验编号 不适用。

数据可用性

MultiSpine基准测试整合了公共数据集与机构队列数据。公共数据组件（CTSpinelK、SpineWeb、VerSe 2020）可通过参考文献中引用的URL和DOI从原始提供方获取。针对这些数据集，我们将在发表时发布一份数据整理清单，其中包含本研究使用的精确病例标识符及训练/验证/测试数据划分，同时提供统一的椎体掩码与标签。针对私有队列（Private A和Private B）的去标识化衍生标签，可根据合理请求向通讯作者获取，但需遵守机构数据使用协议并获得伦理审批。

代码可用性

用于训练VertebraFormer并重现所有实验（包括配置文件、预处理脚本及评估程序）的源代码，将在本研究发表后通过公共代码库以开源许可证形式发布。在此期间，经合理学术研究请求，可向通讯作者获取代码的具体版本及训练模型权重。

致谢

不适用。

资金

本研究获得以下项目资助：国家自然科学基金（编号82203472）、山东省自然科学基金（ZR2023MH202、ZR2024QH042，ZR2025MS1404，and ZR2025MS1307）、山东省医学会2023青年人才支持项目（2023LC0021）、江苏省卫生计生委科研项目（ZQ2024002）、苏州市科技计划（SKY2023114、SKY2022093）。本项目不存在利益冲突。

作者贡献

J.D.、J.H.和Y.B.负责研究 y, conducted investigations, 的构思并监督项目实施。J.D.、H.G.、Y.Z.、F.D.、Z.C.和Y.Zh.负责数据整理并开发研究方法。R.Z.、Y.Z.、H.X.、J.Y.、Y.Y.和J. H.负责正式分析与可视化工作。Z.C.、J.D.和Y.B.负责软件开发与验证。J.D.、H.G.、R.Z.和Y.Y.撰写初稿。J.D.、S.H.和J.H. 审阅并编辑了手稿。J.D.、Y.Y.、S.H.、J.Y.、J.H.和Y.B.负责资金获取、项目管理及资源提供。 所有作者均能查阅研究数据并批准最终稿件。

利益冲突

作者声明无利益冲突。

参考文献

- [1]Qu,B.,Cao,J.,Qian,C.,Wu,J.,Lin,J.,Wang,L.,Ou-Yang,L.,Chen,Y.,
严立、洪庆等：深度学习在脊柱影像分析中的当前发展与前景：文献综述。
《医学与外科定量成像》12(6), 34-54 (2022)
- [2] Simion, G., Eckardt, N., Ullrich, B.W., Senft, C., Schwarz, F.: 采用计算机断层扫描 (CT) 亨氏单位测量的颈椎、胸椎及腰椎骨密度——4350节椎体的结果。BMC Musculoskeletal Disorders 25(1), 200 (2024)
- [3]莱斯曼 (N.)、范·吉内肯 (B.)、德容 (P.A.)、伊斯古姆 (I.)：用于自动椎体分割与识别的迭代全卷积神经网络。 医学影像分析 53,142-155 (2019)
- [4]Sekuboyina,A.,Husseini,M.E.,Bayat,A.,Löffler,M., Liebl, H.、Li, H.、Tetteh, G.、Kukacka、J.、Payer、C.Stern, D. 等：基于多探测器CT图像的椎体标记与分割基准方法。医学图像分析 73,102166 (2021)
- [5]Masuzawa,N.,Kitamura,Y.,Nakamura,K.,Iizuka,S.Simo-Serra, E.: 自动基于级联卷积神经网络的三维CT图像中椎体分割、定位与识别。载于：国际医学影像计算与计算机辅助介入会议, 第681-690页 (2020年)。斯普林格
- [6]程P、杨Y、余H、何Y：基于两阶段Dense-U-Net的CT椎体自动定位与分割。《科学报告》11(1), 22156 (2021)
- [7]伊森西 (F. Isensee)、耶格尔 (P.F. Jaeger)、科尔 (S.A. Kohl)、彼得森 (J. Petersen)、迈尔-海因 (K.H. Maier-Hein)：nnu-net：
基于深度学习的生物医学图像分割自配置方法 《自然方法》18(2), 203-211 (2021)

- [8]Deng, Y., Wang, C., Hui, Y., Li, Q., Li, J., Luo, S., Su M.、全 Q.、杨 S. Hao, Y.等: Ctspinelk: 一种用于计算机断层扫描脊椎分割的大规模数据集。arXiv预印本 arXiv:2105.14711 (2021)
- [9]Li,M.,Gong,W.,Yan,P.,Li,X.,Jiang,Y.,Luo,H.,Zhou,H.,Yin,S.: 基于临床知识感知框架的乳腺超声视频关节病变检测与分类。IEEE视频技术电路与系统汇刊 (2024)
- [10]陈Z、卢S: Caf-yolo——一种用于生物医学影像多尺度病灶检测的鲁棒框架。载于: ICASSP2025-2025 IEEE国际声学、语音与信号处理会议 (ICASSP), 第1-5页 (2025年)。IEEE
- [11]Sekuboyina, A., Valentinitich, A., Kirschke, J.S., Menze, B.H.:A 局部化-分割方法用于基于深度网络的腰椎多标签标注。arXiv预印本arXiv:1703.04347(2017)
- [12]Yoon, J.S., Oh, K., Shin, Y., Mazurowski, M. A., Suk, H.-I.: 域泛化在医学图像分析中的应用综述. IEEE学报 (2024)
- [13]文R、袁H、倪D、肖W、吴Y: 从去噪训练到测试时自适应: 提升医学图像分割的领域泛化能力。载于: IEEE/ CVF 计算机视觉应用冬季会议论文集, 第464-474页 (2024年)。
- 基于形状字典的测试时自适应 [14]Liu, Q., Chen, C., Dou, Q., Heng, P.-A.:Single-domain 泛化在医学图像分割中的应用。载于: 《AAAI人工智能会议论文集》, 第36卷, 第1756-1764页 (2022年)
- [15]Yang, F., Li, X., Wang, B., Zhang, T., Yu, X., Yi, X., Zhu, R.:Mmseg:A 针对医学图像分割中类别不平衡与标签稀缺问题的新型多任务学习框架。《基于知识的系统》309卷, 112835页 (2025年)
- [16]Vatian, A., Tomilov, I., Gritskikh, M., Dobrenko, N., K·哈里托诺夫, A., 瓦利托娃, Y., Gusarova, N.: 基于视觉变换器的多任务学习增强医学图像分析。载于: 国际计算科学会议, 第195-203页 (2025年)。Springer出版社
- [17]Jiang, J., Gu, S.:训练一次, 部署随处:边缘引导的单源域泛化在医学图像分割中的应用。载于:《深度学习在医学影像中的应用》, 第722-741页 (2024)。PMLR
- 采用改进型注意力UNet对腰椎椎体进行 [18]Pal, R., Saha, P., Ghoshal, S., Chakrabarti, A., Sur-Kolay, S.:Panoptic 分割与标记。arXiv预印本 arXiv:2404.18291 (2024)

- [19]Hatamizadeh, A., Tang, Y., Nath, V., Yang, D., Myr A., 兰德曼 B. Roth, H.R., Xu, D.: Unetr: 用于三维医学图像分割的Transformer模型。载于: IEEE/ CVF 计算机视觉应用冬季会议论文集, 第574-584页 (2022年)
- [20]唐, Y., 杨, D., 李, W., 罗斯, H.R., 兰德曼, B., 徐, D., 纳思, V. Hatamizadeh, A.: 自监督预训练的SWINTransformer用于三维医学图像分析。载于: IEEE/ CVF 计算机视觉与模式识别会议论文集, 第20730-20740页 (2022年)
- [21]Thanell, M., Melander, P.: 用于任意成像范围CT扫描中器官与组织分割的视觉变换器。数学科学硕士学位论文 (2024年)
- [22]He, A., Wang, K., Li, T., Du, C., Xia, S., Fu, H.: H2former: 一种用于医学图像分割的高效分层混合变压器。IEEE医学影像学报42(9), 2763-2775 (2023)
- [23]Li, Z., Zheng, Y., Shan, D., Yang, S., Li, Q., Wang, B., Z, 杨, 洪, 沈 D. Scribformer: Transformer使CNN在基于涂鸦的医学图像分割中表现更优。IEEE医学影像学报 43(6), 2254-2265 (2024)
- [24]郭B、曹N、张R、杨P: GetNet: 基于VT-UNET的群归一化洗牌与增强通道自注意力网络用于脑肿瘤分割。《诊断学》14 (12), 1257 (2024)
- [25]Wang, Y., Huang, N., Li, T., Yan, Y., Zhang, X.: Medformer: A 多粒度补丁变换器在医学时间序列分类中的应用。神经信息处理系统进展 37, 36314-36341 (2024)
- [26]Lin, N.: Unetrpt: 一种用于医学图像分割的轻量级网络。见: 2023年中国自动化大会 (CAC), 第2052-2057页 (2023年)。IEEE
- [27]Yin, Y., Luo, S., Zhou, J., Kang, L., Chen, C.Y.-C.: Ldcnet: 用于腹腔镜手术图像分割的轻量级动态卷积网络。《神经网络》170卷441-452页 (2024年)
- [28]余X、何J、杨J、顾Y: 基于显式形状先验的医学图像分割学习方法。IEEE医学影像学报 (2024)
- 医学图像分析中的 [29]He, W., Zhang, Y., Xu, T., An, T., Liang, Y., Zhang, B.: Object 检测: 来自rt-detr模型的启示。见: 2025年 Artificial Intelligence 与 Computational Intelligence International Conference 论文集, 第415-420页 (2025年)
- [30]Aziz, F., Saputri, D. U.E.: 基于yolov9网络的高效皮肤病变检测。

《医学信息学技术》期刊，2024年第11-15期

- [31]贾欣, M. A., Soudeep, S., Mridha, M., Fahad, N., Hossen, M.J.:Dycaf-net: 动态类感知融合网络。arXiv预印本arXiv:2508.03598 (2025)
- [32]Shim,J.H.,Kim,W.S.,Kim,K.G.,Yee,G.T.,Kim,Y.J.,Jeong,T.S.:Automated 基于X射线的颈椎损伤分段与诊断测量评估。医学影像信息学杂志37(4), 1863-1873 (2024)
- [33]Hohenhaus, M., Klingler, J.-H., Scholz, C., Watzlawi ck, R., Hubbe, U., Beck, J. Reiser, M., Wurtemberger, U., Kremers, N., Wolf, K.: 通过自动化三维 MRI分割脊髓与脑脊液空间对颈椎椎管狭窄的量化分析. Spinal Cord 62(7), 371-377 (2024)
- [34]余H、戴Q: 医学图像分析的自监督多任务学习。 模式识别 150,110327 (2024)
- [35]Chen, C., Miao, J., Wu, D., Zhong, A., Yan, Z., Kim, S、胡、刘、孙、李 李X等: Ma-sam: 一种适用于三维医学图像分割的模态无关自适应方法。医 学图像分析 98,103310 (2024)
- 三维医学图像分割基础模型的 [36]Chattopadhyay, S., Demir, B., Niethammer, M.:Zero-shot 域泛化: 一项实验研究。arXiv预印本 arXiv:2503.22862 (2025)
- [37]Mahapatra,D.,Yepes,A.J.,Bozorgtabar,B.,Roy,S.,Ge,Z.,Reyes,M.:Multi- 基于图像-文本信息与特征解耦的胸部X线片通用零点分类方法 IEEE医学影 像汇刊 (2024)
- 零样本与少量样本AI算法在医学领域的 [38]Badawi, M., Abushanab, M., Bhat , S., Maier, A.:Review 。arXiv预印本arXiv:2406.16143 (2024)
- [39]Khadka, R., Jha, D., Hicks, S., Thambawita, V., Riegler , M. A., 阿里, S., 哈尔 沃森, P.: 基于少量样本场景下隐式梯度的医学图像分割元学习。《计算机在生物 学与医学中的应用》143卷, 105227页 (2022年)
- 基于跨域一致性学习的CT体成分 [40]Ali, S., Lee, Y.R., Park, S.Y., Tak, W.Y., Jung, S.K.:Unsupervised 域适应。机器视觉与应用 36(1), 27 (2025)
- [41]徐, Y., 汗, T.M., 宋, Y., 梅杰林, E.:计算机视觉与医学诊断中的边缘学 习:综述.《人工智能评论》58(3), 93 (2025)
- [42]Liu, X., Chen, Z., Tang, Z., Yang, X., Jiang, Y., Zheng, D , 蒋, F., 尼, F., 郭,

- S., Qian, Q. 等: 基于深度学习的胸部CT放射性异物吸入自动检测。npj Digital Medicine 8(1), 647 (2025)
- 一种低运算量高精度的图像识别 [43]Hsia, S.-C., Wang, S.-H., Chang, C.-Y.: Convolution 神经网络。《实时图像处理杂志》18(4), 1309-1319 (2021)
- [44]Zhu, Y., Li, Y., Wang, K., Li, J., Zhang, X., Zhang, Y., Li, J., Wang, X.: A 健康成人颈椎MRI分段与测量深度学习模型的定量评估。《应用临床医学物理学杂志》25(3), 14282 (2024)
- [45]Bae, H.-J., Hyun, H., Byeon, Y., Shin, K., Cho, Y. 宋, Y.J., 印, S., 库, S.-U., Yeom, J.S., Kim, N.: 基于二维卷积神经网络的CT图像中多节颈椎完全自动化三维分割与分离 计算机方法与程序在生物学中的应用 184, 105119 (2020)
- [46]Wang, W., Chen, C., Ding, M., Yu, H., Zha, S., Li, J.: Transbts: 使用 Transformer 进行多模态脑肿瘤分割。载于: 国际医学图像计算与计算机辅助干预会议, 第109-119页 (2021年)。 斯普林格
- [47]Zhang, Y., Li, J., Yang, Q., Yin, S., Hou, J., Cao, X., Ma, M., 王 B., 罗 M., 周F. 等: 一种基于CT扫描的临床适用性人工智能系统用于骨转移的检测与诊断。《自然·通讯》16(1), 4444 (2025)
- [48]李X、洪Y、徐Y、胡M: Verformer: 基于椎体感知的CT图像自动脊柱分割变换器。《诊断学》14 (17), 1859 (2024)
- [49]Tao, R., Liu, W., Zheng, G.: Spine-transformers: 通过三维变换器对任意视野脊柱CT图像进行椎体标记与节段分割。医学图像分析 75, 102258 (2022)
- [50]You, X., Gu, Y., Liu, Y., Lu, S., Tang, X., Yang, J.: Verteformer: A 任意视场CT图像的椎体分割单级变换网络。《医学物理学》50 (10), 6296-6318 (2023)
- [51]Klein, G., Hardisty, M., Whyne, C., Martel, A.L.: Vertdetect: 完整的端到端三维椎体实例分割模型。arXiv预印本arXiv:2311.09958 (2023)
- [52]Zhang, S., Chen, M., Wu, J., Zhang, Z., Li, T., Xue, C., Kong, Y.: Spineclue: 基于对比学习与不确定性估计的自动椎体识别研究。arXiv预印本arXiv:2401.07271 (2024)
- [53]黄, Y., 乌内里, A., 琼斯, C., 张, X., 凯奇a, M., 阿伊贡, N., 赫尔姆, P., Siewerdsen, J.: 脊柱CT中第三椎体标记: 一种精确且内存高效的 (正交二维) 框架。《医学与生物学物理学》66 (12), 125020 (2021)

- [54]Cui,Z.,Li,C.,Yang,L.,Lian,C.,Shi,F.,Wang,W.,Wu,D.,Shen,D.:Vert-net: 基于CT图像的椎体精确定位与识别网络。见: 国际医学影像计算与计算机辅助干预会议, 第281-290页(2021年)。Springer
- [55]Wu, H., Bailey, C., Rasoulinejad, P., Li, S.:Automatic 青少年特发性脊柱侧凸评估的特征点估计——基于boostnet方法。载于: 国际医学图像计算与计算机辅助干预会议, 第xx页。127-135(2017). Springer
- [56]Yu,Q-S.,Shan,J.-Y.,Ma,J.,Gao,G.,Tao,B.-Z.,Qiao,G.-Y.,Zhang,J.-N.,王T、赵Y.-F、秦X.-L等: 多模态多视角颈椎病影像数据集。《科学数据》12(1), 1080 (2025)
- [57]Shastri, P., Sonawane, B., Mohan, K., Kumarasami, N.、斯里帕德拉杰 R.、SP K. Venkatesh, K.P., Subramanian, B., Sivasailam, K., et 等: 人工智能与深度学习在MRI脊柱结构自动化分割及定量测量中的应用。arXiv预印本 arXiv:2503.11281 (2025)
- [58]Gomez Mesa, L.M.:CT扫描中用于体成分分析的椎旁肌节段划分 (2025)
- [59]Chen,T.,Ding,C.,Zhu,L.,Xu,T.,Ji,D.,Wang,Y.,Zang,Y.,Li,Z.:xlstm-unet 可作为有效的二维与三维医学图像分割骨干网络, 其性能优于Mamba架构的对应模型。arXiv预印本 arXiv:2407.01530 (2024)
- [60]Noh, S., Lee, B.-D.:医学图像分割基础模型的叙述性综述: 基于多模态零样本性能评估。医学与外科定量成像 15(6), 5825 (2025)
- [61]Moshiri, P.F., Shahbazian, R., Nabati, M., Ghorashi, S. A.: 一种基于CSI(计算机辅助识别)的人类基于深度学习的活动识别。《传感器》21 (21), 7225 (2021)